

# Trabajo final



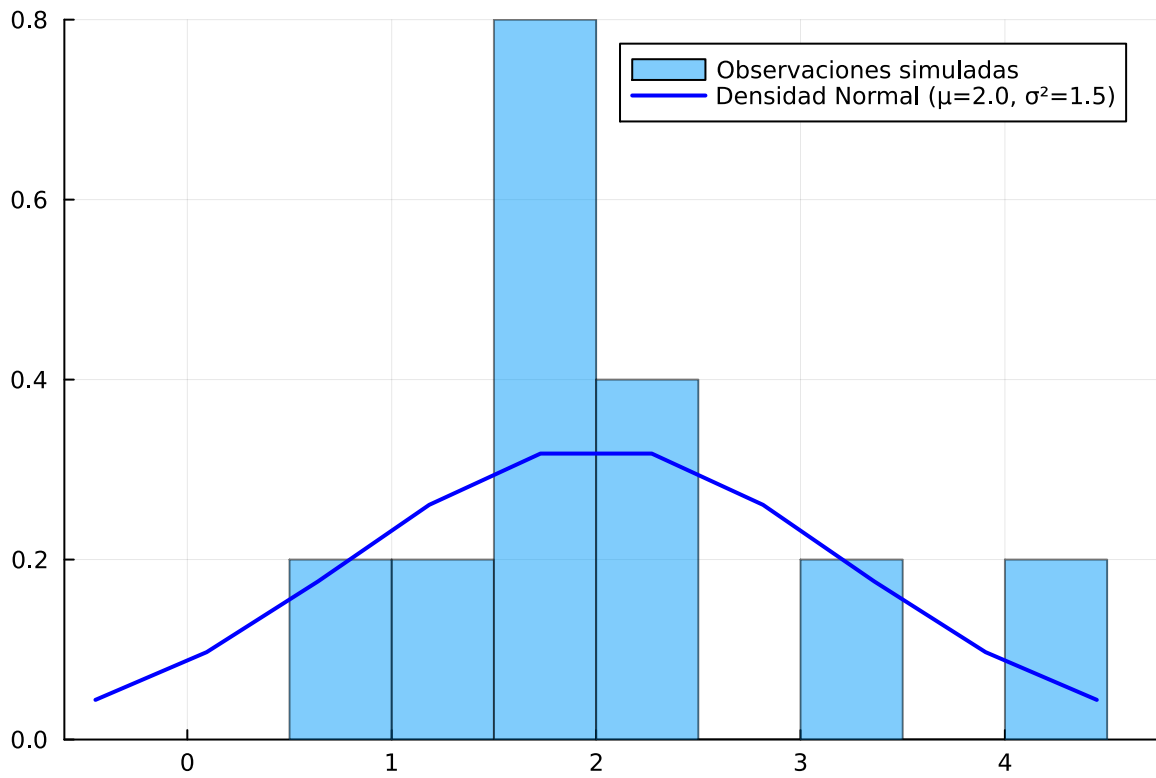
Alumno: Hugo Marlon Fernandez Quiroz

1. Considere las variables aleatorias  $Y_i \sim \text{Normal}(\mu, \sigma^2)$  para  $i = 1, \dots, n$ , en donde el vector de parámetros es  $\theta = (\mu, \sigma^2)$ :

(a) Simule las observaciones para  $n = 10$  para obtener  $\mathbf{y} = [y_1, y_2, \dots, y_{10}]^T$ .

[2.21836, 1.90046, 1.01509, 1.87073, 1.94512, 1.92636, 0.518093, 2.01743, 3.16654, 4.25804]

```
1 begin
2   # Definir parámetros
3   μ = 2.0           # Media
4   σ² = 1.5          # Varianza
5   n = 10            # Número de observaciones
6
7   # Simular las observaciones
8   y = μ .+ sqrt(σ²) .* randn(n)
9 end
```



(b) Obtener la función de verosimilitud  $L(\theta)$  y log-verosimilitud  $\ell(\theta)$  asociada a las observaciones  $y_1, y_2, \dots, y_{10}$ . Interprete la forma que tenga la función de verosimilitud.

Dado que las observaciones  $y_1, y_2, \dots, y_{10}$  siguen una distribución normal  $Y_i \sim \text{Normal}(\mu, \sigma^2)$ , la función de verosimilitud  $L(\theta)$  se define como:

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \mu)^2}{2\sigma^2}\right)$$

Donde  $\theta = (\mu, \sigma^2)$  es el vector de parámetros.

La log-verosimilitud  $\ell(\theta)$  es el logaritmo natural de la función de verosimilitud:

$$\ell(\mu, \sigma^2) = \log L(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2$$

```

1 begin
2     function verosimilitud(y, μ, σ²)
3         n = length(y)
4         (1 / ((2 * π * σ²)^(n/2))) * exp(-sum((y .- μ).^2) / (2 * σ²))
5     end
6
7     # Log-verosimilitud
8     function log_verosimilitud(y, μ, σ²)
9         n = length(y)
10        -(n/2) * log(2 * π * σ²) - sum((y .- μ).^2) / (2 * σ²)
11    end
12
13    println("Verosimilitud: ", verosimilitud(y, μ, σ²))
14    println("Log-verosimilitud: ", log_verosimilitud(y, μ, σ²))
15 end

```

```

Verosimilitud: 5.286492839449081e-7
Log-verosimilitud: -14.452940604266272

```



### c) Obtener la función de score $S(\theta)$ y la información de Fisher $I_E(\theta)$

La *función score* es la derivada de la log-verosimilitud con respecto a los parámetros  $\mu$  y  $\sigma^2$ :

Para  $\mu$ :

$$S_{\mu}(\mu, \sigma^2) = \frac{\partial \ell(\mu, \sigma^2 | y)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \mu)$$

Para  $\sigma^2$ :

$$S_{\sigma^2}(\mu, \sigma^2) = \frac{\partial \ell(\mu, \sigma^2 | y)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (y_i - \mu)^2$$

La *información de Fisher* es la matriz de varianza-covarianza inversa de los estimadores de máxima verosimilitud, cuyas entradas son los valores esperados de los productos de las derivadas de la log-verosimilitud:

Para  $\mu, \sigma^2$ :

$$\mathcal{I}(\mu, \sigma^2) = \begin{pmatrix} \frac{n}{\sigma^2} & 0 \\ 0 & \frac{n}{2\sigma^4} \end{pmatrix}$$

```

1 begin
2     function score(y, μ, σ²)
3         n = length(y)
4         dL_dμ = sum(y .- μ) / σ²
5         dL_dσ² = -(n / (2 * σ²)) + sum((y .- μ).^2) / (2 * σ²^2)
6         return dL_dμ, dL_dσ²
7     end
8
9     # Información de Fisher
10    function fisher_information(y, μ, σ²)
11        n = length(y)
12        I_μμ = n / σ²
13        I_μσ² = 0
14        I_σ²σ² = n / (2 * σ²^2)
15        return I_μμ, I_μσ², I_σ²σ²
16    end
17
18    println("Score: ", score(y, μ, σ²))
19    println("Información de Fisher: ", fisher_information(y, μ, σ²))
20
21 end

```

```

Score: (0.5574855579592516, -1.1758468455475186)
Información de Fisher: (6.666666666666667, 0, 2.222222222222223)

```



**(d) Dado un conjunto de observaciones simuladas, obtenga intervalos de confianza utilizando la distribución asintótica del estimador de máxima verosimilitud.**

Los estimadores de máxima verosimilitud para  $\mu$  y  $\sigma^2$  son:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n y_i, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{\mu})^2$$

Para el intervalo de confianza de  $\mu$ :

$$\hat{\mu} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{\sigma}^2}{n}}$$

donde  $z_{\alpha/2}$  es el valor crítico de la distribución normal estándar.

Para  $\sigma^2$ , el intervalo de confianza es:

$$\left( \frac{(n-1)\hat{\sigma}^2}{\chi_{\alpha/2, n-1}^2}, \frac{(n-1)\hat{\sigma}^2}{\chi_{1-\alpha/2, n-1}^2} \right)$$

donde  $\chi_{\alpha, k}^2$  es el valor crítico de la distribución chi-cuadrado con  $k$  grados de libertad.

```

1 begin
2   μ_hat = mean(y)
3   σ2_hat = var(y)
4
5   # Intervalos de confianza
6   α = 0.05 # Nivel de significancia
7   z = quantile(Normal(0, 1), 1 - α/2)
8
9   conf_μ = (μ_hat - z * sqrt(σ2_hat / n), μ_hat + z * sqrt(σ2_hat / n))
10  conf_σ2 = (σ2_hat * (n - 1) / quantile(Chisq(n - 1), 1 - α/2), σ2_hat * (n - 1)
11            / quantile(Chisq(n - 1), α/2))
12
13  println("Intervalo de confianza para μ: ", conf_μ)
14  println("Intervalo de confianza para σ2: ", conf_σ2)
15
16 end

```

```

Intervalo de confianza para μ: (1.4422102862101966, 2.725035381177578)
Intervalo de confianza para σ2: (0.5066960556904075, 3.569396715531712)

```



(e) Dado un conjunto de observaciones simuladas, obtenga intervalos de confianza utilizando la devianza.

La devianza es una medida de la calidad del ajuste del modelo. Se define como:

$$D = -2 \cdot \ell(\hat{\mu}, \hat{\sigma}^2 | y)$$

Para construir intervalos de confianza usando la devianza, se compara con la distribución  $\chi^2$  asintótica bajo ciertas condiciones del modelo.

```

1 begin
2   function devianza(y, μ_hat, σ2_hat)
3     -2 * log_verosimilitud(y, μ_hat, σ2_hat)
4   end
5
6   # Intervalos de confianza con la devianza (asume chi-cuadrado)
7   conf_devianza = [devianza(y, μ_hat, σ2_hat) + quantile(Chisq(1), α/2),
8                   devianza(y, μ_hat, σ2_hat) + quantile(Chisq(1), 1 - α/2)]
9   println("Intervalo de confianza usando la devianza: ", conf_devianza)
10 end

```

```

Intervalo de confianza usando la devianza: [28.065433121083213, 33.08833723
9280925]

```



(f) Simulando otra muestra  $x_1, x_2, \dots, x_n$  con distinta media ( $Normal(\mu_2, \sigma^2)$ ). Realizar la prueba de hipótesis para  $\mu_1 = \mu_2$  utilizando la prueba de razones de verosimilitud.

Para probar la hipótesis  $H_0 : \mu_1 = \mu_2$  contra  $H_1 : \mu_1 \neq \mu_2$ , usamos la razón de verosimilitudes:

$$\Lambda = -2 [\ell(\hat{\mu}, \hat{\sigma}^2 | y) - (\ell(\hat{\mu}_1, \hat{\sigma}_1^2 | y_1) + \ell(\hat{\mu}_2, \hat{\sigma}_2^2 | y_2))]$$

```

1 begin
2   # segunda muestra
3   x_new = rand(Normal(0, sqrt( $\sigma^2$ )), n)
4
5   # Hipótesis nula:  $\mu_1 = \mu_2$ 
6   logL0 = log_verosimilitud([y; x_new], mean([y; x_new]),  $\sigma_2\_hat$ )
7   # Hipótesis alternativa:  $\mu_1 \neq \mu_2$ 
8   logL1 = log_verosimilitud(y, mean(y),  $\sigma_2\_hat$ ) + log_verosimilitud(x_new,
    mean(x_new),  $\sigma_2\_hat$ )
9
10  # Estadístico de prueba
11  LR = -2 * (logL0 - logL1)
12
13  # P-valor
14  p_value = 1 - cdf(Chisq(1), LR)
15  println("Razón de verosimilitudes: ", LR)
16  println("P-valor: ", p_value)
17
18  significancia = 0.05
19  if p_value < significancia
20      println("Se rechaza la hipótesis nula al 95% de significancia")
21  else
22      println("Se acepta la hipótesis nula")
23  end
24 end

```

```

Razón de verosimilitudes: 13.00915122505365
P-valor: 0.0003099724098317713
Se rechaza la hipótesis nula al 95% de significancia

```



2. Continuando con el problema anterior, asuma los priors  $\mu \sim \text{Normal}(\mu_0, \sigma_0^2)$  y  $\sigma^2 \sim \text{InverseGamma}(a, b)$ .

(a) Dada la muestra simulada  $y$ , obtener la distribución aposteriori condicional  $\pi(\mu \mid \sigma^2, y)$ .

Dada la muestra  $y = (y_1, y_2, \dots, y_n)$ , y suponiendo que  $\sigma^2$  es conocida:

1. *Modelo*: Supongamos que los datos son independientes y normalmente distribuidos:

$$y_i \mid \mu, \sigma^2 \sim \text{Normal}(\mu, \sigma^2), \quad i = 1, 2, \dots, n$$

Es decir, la función de verosimilitud es:  $p(y \mid \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \mu)^2}{2\sigma^2}\right)$

Esto se puede escribir como:  $p(y \mid \mu, \sigma^2) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2\right)$

2. *Prior de  $\mu$* : El prior de  $\mu$  es una distribución normal:  $\mu \sim \text{Normal}(\mu_0, \sigma_0^2)$

Entonces, la función de densidad del prior es:  $p(\mu) = \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp\left(-\frac{(\mu - \mu_0)^2}{2\sigma_0^2}\right)$

3. *Posterior de  $\mu$* : La posterior de  $\mu$  dado  $\sigma^2$  y los datos es proporcional al producto de la verosimilitud y el prior:

$$p(\mu \mid \sigma^2, y) \propto p(y \mid \mu, \sigma^2) p(\mu)$$

Sustituyendo las expresiones de la verosimilitud y el prior:

$$p(\mu \mid \sigma^2, \mathbf{y}) \propto \exp \left( -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 - \frac{1}{2\sigma_0^2} (\mu - \mu_0)^2 \right)$$

4. *Completando el cuadrado*: Simplificamos la expresión completando el cuadrado en  $\mu$ :

$$p(\mu \mid \sigma^2, \mathbf{y}) \propto \exp \left( -\frac{1}{2} \left( \frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \right) (\mu - \mu_n)^2 \right)$$

donde:  $\mu_n = \frac{\frac{\mu_0}{\sigma_0^2} + \frac{n\bar{y}}{\sigma^2}}{\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}}, \quad \sigma_n^2 = \left( \frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \right)^{-1}$

Así, se obtiene que:  $\mu \mid \sigma^2, \mathbf{y} \sim \text{Normal}(\mu_n, \sigma_n^2)$

```

1 begin
2   # Parámetros a priori
3   μ0 = 0.0
4   σ0² = 1.0
5
6   # Datos simulados
7   y_bayes = rand(1:100, 5)
8   n_bayes = length(y)
9   ȳ = mean(y)
10
11  # Dado un valor de σ²
12  σ²_bayes = 1.0 # Supón que es un valor conocido o inicial
13
14  # Parámetros de la distribución a posteriori de μ
15  μ_n = (σ0² * ȳ + σ² * μ0) / (n_bayes * σ0² + σ²_bayes)
16  σ_n² = (σ0² * σ²) / (n_bayes * σ0² + σ²_bayes)
17
18  # Distribución a posteriori condicional de μ dado σ² y y
19  posterior_μ = Normal(μ_n, sqrt(σ_n²))
20
21  # Print para la sección (a)
22  println("Distribución a posteriori condicional de μ | σ², y:")
23  println("μ ~ Normal($μ_n, $(sqrt(σ_n²)))")
24
25 end

```

Distribución a posteriori condicional de  $\mu \mid \sigma^2, y$ :  
 $\mu \sim \text{Normal}(0.1894202576085352, 0.3692744729379982)$



**(b) Dada la muestra simulada  $y$ , obtener la distribución aposteriori condicional  $\pi(\sigma^2 \mid \mu, y)$ .**

Dada la muestra  $\mathbf{y} = (y_1, y_2, \dots, y_n)$ , y suponiendo que  $\mu$  es conocida:

1. *Modelo*: Como antes, los datos siguen una distribución normal:  $y_i \mid \mu, \sigma^2 \sim \text{Normal}(\mu, \sigma^2)$

Entonces, la función de verosimilitud es:

$$p(\mathbf{y} \mid \mu, \sigma^2) = \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp \left( -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 \right)$$

2. **Prior de  $\sigma^2$** : El prior de  $\sigma^2$  es una distribución Inversa Gamma:  $\sigma^2 \sim \text{InverseGamma}(a, b)$

Entonces, la función de densidad del prior es:

$$p(\sigma^2) \propto (\sigma^2)^{-(a+1)} \exp \left( -\frac{b}{\sigma^2} \right)$$

3. **Posterior de  $\sigma^2$** : La posterior de  $\sigma^2$  dado  $\mu$  y los datos es proporcional al producto de la verosimilitud y el prior:

$$p(\sigma^2 \mid \mu, \mathbf{y}) \propto p(\mathbf{y} \mid \mu, \sigma^2) p(\sigma^2)$$

Sustituyendo las expresiones de la verosimilitud y el prior:

$$p(\sigma^2 \mid \mu, \mathbf{y}) \propto (\sigma^2)^{-\frac{n}{2}-(a+1)} \exp \left( -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 - \frac{b}{\sigma^2} \right)$$

4. **Reconociendo la forma**: Esta expresión es de la forma de una distribución Inversa Gamma:

$$p(\sigma^2 \mid \mu, \mathbf{y}) \sim \text{InverseGamma}(a_n, b_n)$$

donde:  $a_n = a + \frac{n}{2}$ ,  $b_n = b + \frac{1}{2} \sum_{i=1}^n (y_i - \mu)^2$

```

1 begin
2     # Parámetros a priori
3     a = 1.0
4     b = 0.0
5
6     # Parámetros de la distribución a posteriori de  $\sigma^2$ 
7      $\alpha_n$  = a + n/2
8      $\beta_n$  = b + 0.5 * sum((y .-  $\mu$ ).^2)
9
10    # Distribución a posteriori condicional de  $\sigma^2$  dado  $\mu$  y y
11    posterior_ $\sigma^2$  = InverseGamma( $\alpha_n$ ,  $\beta_n$ )
12
13    # Print para la sección (b)
14    println("Distribución a posteriori condicional de  $\sigma^2$  |  $\mu$ , y:")
15    println(" $\sigma^2 \sim \text{InverseGamma}(\alpha_n, \beta_n)$ ")
16
17 end

```

Distribución a posteriori condicional de  $\sigma^2$  |  $\mu$ , y:  
 $\sigma^2 \sim \text{InverseGamma}(6.0, 4.854344597518083)$



(c) **Utilice el muestreo de Gibbs para obtener realizaciones de la distribución aposteriori  $\pi(\mu, \sigma^2 | \mathbf{y})$ .**

El muestreo de Gibbs es una técnica de muestreo secuencial que se basa en muestrear de las distribuciones condicionales completas:

1. **Inicialización**: Asigne valores iniciales  $\mu^{(0)}$  y  $\sigma^{2(0)}$ .
2. **Iteración**:



- Muestree  $\mu^{(t)} \sim \text{Normal}(\mu_n, \sigma_n^2)$  dado  $\sigma^{2(t-1)}$ .
- Muestree  $\sigma^{2(t)} \sim \text{InverseGamma}(a_n, b_n)$  dado  $\mu^{(t)}$ .

Se repite estos pasos para obtener una cadena de muestras  $\{(\mu^{(t)}, \sigma^{2(t)})\}_{t=1}^T$  que convergerá a la distribución conjunta posterior.

```

1 begin
2   iterations = 10000
3   burn_in = 2000
4   mu_samples = zeros(iterations)
5   sigma2_samples = zeros(iterations)
6
7   # Valores iniciales
8   mu_samples[1] = mean(y)
9   sigma2_samples[1] = var(y)
10
11  # Iteraciones del muestreo de Gibbs
12  for i in 2:iterations
13    # Muestreo de  $\mu$  dado  $\sigma^2$ , y
14    sigma2 = sigma2_samples[i-1]
15    mu_n = (sigma0^2 * y_bar + sigma^2 * mu0) / (n * sigma0^2 + sigma^2)
16    sigma_n^2 = (sigma0^2 * sigma^2) / (n * sigma0^2 + sigma^2)
17    mu_samples[i] = rand(Normal(mu_n, sqrt(sigma_n^2)))
18
19    # Muestreo de  $\sigma^2$  dado  $\mu$ , y
20    alpha_n = a + n/2
21    beta_n = b + 0.5 * sum((y .- mu_samples[i]).^2)
22    sigma2_samples[i] = 1 / rand(Gamma(alpha_n, 1/beta_n))
23  end
24
25  # Print para la sección (c)
26  println("Muestreo de Gibbs completado con $iterations iteraciones.")
27
28  # Mostrar algunas realizaciones de las muestras
29  println("\nAlgunas realizaciones de las muestras de  $\mu$  y  $\sigma^2$ :")
30  for i in 1:5 # Imprime las primeras 5 realizaciones como ejemplo
31    println("Iteración $i:  $\mu$  = $(mu_samples[i + burn_in]),  $\sigma^2$  = $(sigma2_samples[i + burn_in])")
32  end
33
34 end

```

Muestreo de Gibbs completado con 10000 iteraciones. ?

Algunas realizaciones de las muestras de  $\mu$  y  $\sigma^2$ :

Iteración 1:	$\mu$ = 0.46643981723670713,	$\sigma^2$ = 2.705781497725431
Iteración 2:	$\mu$ = -0.21395447329451753,	$\sigma^2$ = 5.7187304739861435
Iteración 3:	$\mu$ = -0.42574792430690733,	$\sigma^2$ = 6.656350321341007
Iteración 4:	$\mu$ = -0.5551904831033352,	$\sigma^2$ = 6.054644893483367
Iteración 5:	$\mu$ = 1.3777046636507986,	$\sigma^2$ = 1.018566872404387

(d) Usando realizaciones de la distribución aposteriori, proporcione inferencia puntual y por intervalos para ambos parámetros.

```
1 begin
2   # Descartar el burn-in
3    $\mu$ _samples_new =  $\mu$ _samples[burn_in+1:end]
4    $\sigma^2$ _samples_new =  $\sigma^2$ _samples[burn_in+1:end]
5
6   # Calcular la media posterior y los intervalos creíbles
7    $\mu$ _mean = mean( $\mu$ _samples_new)
8    $\sigma^2$ _mean = mean( $\sigma^2$ _samples_new)
9    $\mu$ _cred_int = quantile( $\mu$ _samples_new, [0.025, 0.975])
10   $\sigma^2$ _cred_int = quantile( $\sigma^2$ _samples_new, [0.025, 0.975])
11
12  # Print para la sección (d)
13  println("Resultados de la inferencia:")
14  println("Media posterior de  $\mu$ :  $\mu$ _mean")
15  println("Intervalo creíble del 95% para  $\mu$ :  $\mu$ _cred_int")
16  println("Media posterior de  $\sigma^2$ :  $\sigma^2$ _mean")
17  println("Intervalo creíble del 95% para  $\sigma^2$ :  $\sigma^2$ _cred_int")
18
19 end
```

Resultados de la inferencia: ?  
Media posterior de  $\mu$ : 0.13751794554254895  
Intervalo creíble del 95% para  $\mu$ : [-1.0113042499919969, 1.2483559409937413]  
Media posterior de  $\sigma^2$ : 5.074286530378358  
Intervalo creíble del 95% para  $\sigma^2$ : [1.2116938899967393, 14.144587725648709]